

Project Proposal

ระบบติดตามและสรุปทิศทางความรู้สึกของข่าวหุ้นแบบใกล้เคียงเวลาจริง เพื่อสนับสนุนการติดตามข้อมูลของนักลงทุนรายย่อย (Stock News Sentiment)

โครงการนี้พัฒนาระบบติดตามทิศทางข่าวหุ้นสหรัฐฯ แบบใกล้เคียงเวลาจริง บน Data Lakehouse ที่รองรับข่าวย้อนหลังหลายปีและข่าวใหม่ ณ ปัจจุบัน

1. ที่มาและความสำคัญ

นักลงทุนรายย่อยที่ลงทุนหุ้นสหรัฐฯ ต้องติดตามข่าวจำนวนมากจากหลายแหล่งทุกวัน และต้องตีความเองว่าข่าวเหล่านั้นเป็นบวกหรือลบต่อหุ้นที่ถืออยู่ เครื่องมือที่มีอยู่มักแสดงข่าวเป็นรายการยาว ไม่สรุปทิศทางให้หรือเป็นบริการเสียเงินสำหรับมืออาชีพ

ปัจจุบันมีเทคโนโลยีที่ช่วยแก้ปัญหานี้ได้ ได้แก่ โมเดลภาษาด้านการเงินอย่าง FinBERT ที่จำแนก sentiment ของข่าวได้อัตโนมัติ และ LLM ที่สรุปและตอบคำถามจากข่าวได้ แต่การนำมาใช้จริงต้องมีระบบข้อมูลที่รับข่าวอย่างต่อเนื่อง ตัดข่าวซ้ำ และเก็บข่าวดิบไว้ประมวลผลใหม่ได้

ข่าวที่ระบบรับเข้ามาสะสมเพิ่มขึ้นทุกวัน และต้องใช้ร่วมกันทั้งหน้าเว็บ การวิเคราะห์ และ LLM โครงการจึงเลือก Data Lakehouse เพราะเก็บข่าวดิบไว้ประมวลผลใหม่ได้เมื่อเปลี่ยนโมเดล ย้อนดูข้อมูล ณ เวลาก่อนหน้าได้ (time travel) และใช้ข้อมูลชุดเดียวกันได้หลายงานผ่าน SQL

2. ปัญหาที่ต้องการแก้

1. ข่าวมาจากหลายแหล่ง ต้องเปิดหลายที่เพื่อติดตามหุ้นตัวเดียว
2. มองภาพรวมไม่ออกว่าข่าวล่าสุดของหุ้นเป็นบวก กลาง หรือลบ
3. ต้องอ่านและตีความเอง ซึ่งใช้เวลาและต้องมีการสรุป
4. อยากถามคำถามเกี่ยวกับข่าวของหุ้น เช่น ทำไมช่วงนี้ข่าวเป็นลบ แต่ไม่มีเครื่องมือที่ตอบจากข่าวจริงพร้อมแหล่งอ้างอิง

3. วัตถุประสงค์

โครงการมีวัตถุประสงค์ 5 ข้อ แต่ละข้อมีตัวชี้วัดที่ตรวจสอบได้ ค่าเป้าหมายเป็นค่าเบื้องต้น จะยืนยันหลังทำ PoC ในเทอม 1

1. เพื่อพัฒนา Data Lakehouse บน Amazon S3 + Apache Iceberg ที่เก็บข่าว ผล sentiment และราคาปิดของหุ้นประมาณ 50 ตัว แบ่งเป็นชั้น Raw / Cleaned / Aggregated
 - o ข่าวที่เข้าแบบ streaming กับราคาปิดที่เข้าแบบ batch อยู่ในตารางชุดเดียวกัน และ query รวมกันผ่าน Athena ได้

- o ไม่มีข่าวซ้ำในชั้น Cleaned (duplicate rate = 0%)
- o ประมวลผล sentiment ใหม่ทั้งหมดจากชั้น Raw ได้เมื่อเปลี่ยนโมเดล โดยไม่ต้องดึงข่าวจากแหล่งใหม่
- o สาธิต time travel และ schema evolution ของ Iceberg ได้จริง
- 2. เพื่อพัฒนา pipeline รับข่าวแบบใกล้เคียงเวลาจริง ด้วย Kafka และ Spark Structured Streaming
 - o ข่าวใหม่แสดงบนเว็บภายใน 15 นาทีหลังแหล่งข่าวเผยแพร่
 - o ระบบทำงานต่อเนื่องได้ไม่น้อยกว่า 7 วันโดยไม่สูญหายข่าว (ฟื้นจาก checkpoint ได้เมื่อหยุดทำงาน)
- 3. เพื่อจำแนก sentiment รายข่าว เป็น Positive / Neutral / Negative ด้วย FinBERT
 - o วัดกับชุดข่าวที่ทีมติดป้ายเอง 300 ข่าว ได้ Macro-F1 ≥ 0.70
- 4. เพื่อพัฒนาเว็บแอป ที่แสดงภาพรวม sentiment ราคาปิดรายวัน และข่าวล่าสุดของหุ้นที่ผู้ใช้เลือก
 - o หน้า Search, Home และ Stock Detail ทำงานครบ
 - o ทดสอบกับผู้ใช้ 10 คน ได้คะแนน SUS ≥ 68
- 5. เพื่อพัฒนา LLM สรุปข่าวประจำวันและระบบถามตอบจากข่าว (News RAG)
 - o สรุป 50 ชิ้น ไม่มีข้อมูลแต่งขึ้นไม่น้อยกว่า 90%
 - o คำถาม 50–100 ข้อ ค้นข่าวถูกหุ้น อ้างอิงแหล่งถูกต้อง และปฏิเสธคำถามนอกขอบเขตได้ไม่น้อยกว่า 90%


4. ขอบเขต

ด้าน	อยู่ในขอบเขต	ไม่อยู่ในขอบเขต
หุ้น	หุ้นสหรัฐฯ ประมาณ 50 ตัว หลากกลุ่มอุตสาหกรรม (Tech, Auto, Energy, space)	หุ้นไทย คริปโต
ข่าว	ข่าวภาษาอังกฤษ ย้อนหลังตั้งแต่ปี 2020 และข่าวใหม่ทุก 5–15 นาที	โพสต์โซเชียล (X, Reddit, StockTwits)
ราคา	ราคาปิดรายวันจาก Yahoo Finance ตั้งแต่ปี 2020	ราคาระหว่างวัน
การวิเคราะห์	sentiment รายข่าวและภาพรวมรายหุ้นรายวัน เทียบกับทิศทางราคาปิด	ทำนายราคา คำแนะนำซื้อขาย
เว็บแอป	หน้า Search, Home (Watchlist), Stock Detail, Ask AI	แอปมือถือ
AI	LLM สรุปข่าว, RAG ตอบเฉพาะหุ้นในระบบพร้อมแหล่งอ้างอิง	ฝึกโมเดลภาษาใหม่เอง

5. แนวทางและสถาปัตยกรรม

ข้อมูลเข้า 2 ทาง แต่ลงตาราง Iceberg ชุดเดียวกัน ซึ่งเป็นสิ่งที่โครงการต้องพิสูจน์ว่า Data Lakehouse ทำงานได้จริง

ข่าวใหม่และราคาปิดรวมในตาราง Iceberg ชุดเดียวกัน



สถาปัตยกรรมระบบ · batch + streaming → Lakehouse → เว็บและ AI

- **Streaming:** ข่าวใหม่ผ่าน Kafka และ Spark Structured Streaming ทุก 5–15 นาที คือส่วน near real-time ของระบบ
- **Batch:** ราคาปิดรายวันจาก Yahoo Finance โหลดวันละครั้ง และงานประมวลผล sentiment ใหม่จากชั้น Raw เมื่อเปลี่ยนโมเดล
- **Serving:** เว็บแอปอ่านชั้น Aggregated ผ่าน Athena ส่วน LLM และ RAG ใช้ข่าวจากชั้น Cleaned

6. แผนการดำเนินงาน

เทอม 1/2569 ทำ Proof of Concept เพื่อพิสูจน์ว่าเครื่องมือแต่ละตัว ใช้งานได้จริง เทอม 2/2570 พัฒนาเต็ม

งาน	สิ่งที่ต้องพิสูจน์	เกณฑ์ผ่าน
ดึงข่าวสดและราคา	API ข่าวและ Yahoo Finance เชื่อมต่อได้ และรู้ rate limit จริง	ดึงข่าวและราคาของ 10 หุ้นได้ครบ
Kafka → Spark → Iceberg	ข่าวโหลดจาก Kafka ลงตาราง Iceberg บน S3 ได้	ข่าวใหม่ปรากฏในตารางภายใน 15 นาที

งาน	สิ่งที่ต้องพิสูจน์	เกณฑ์ผ่าน
ราคาปิดแบบ batch	ราคาปิดรายวันกับข่าว streaming อยู่ในตารางชุดเดียวกัน	Query ข่าวคู่กับราคาผ่าน Athena ได้
Time travel และ reprocess	ย้อนดูตาราง ณ เวลาก่อนหน้า และรัน sentiment ใหม่จากชั้น Raw ได้	สาธิตได้กับข่าวชุดทดสอบ
FinBERT	ความแม่นยำและความเร็วบนข่าวจริง	วัด F1 บน 100 ข่าว และวัดจำนวนข่าวต่อวินาที
LLM สรุปข่าว	สรุปข่าวของหุ้นหนึ่งตัวได้ถูกต้อง	สรุป 5 ชั้ น ตรวจสอบด้วยคน พร้อมค่าใช้จ่ายต่อชั้ น
News RAG	ค้นข่าวถูกหุ้ นและตอบพร้อมแหล่งอ้างอิง	ตอบ 10 คำถามทดสอบได้
UX/UI	ผู้ส่ ใช้งานเข้าใจหน้าจอ	Prototype ครบ 4 หน้า และหน้า Stock Detail ดึงข้อมูลจริงได้

7. การวัดผลและการทดสอบ

ทุกวัตถุประสงค์มีวิธีวัดที่ทำซ้ำได้และค่าเป้าหมายชัดเจน

วัตถุประสงค์	วิธีวัด	ตัวชี้วัด	เป้าหมาย
1. Data Lakehouse	Query ข่าวคู่กับราคาผ่าน Athena เทียบมีและไม่มี partition	เวลา query, ข้อมูลที่ Athena สแกน	query $\leq$ 5 วินาที
1. Data Lakehouse	ตรวจสอบชั้น Cleaned หาข่าวซ้ำ สาธิต time travel, schema evolution และรัน sentiment ใหม่จากชั้น Raw	duplicate rate, ผลการสาธิต	0%, สาธิตได้ครบทุกข้อ
2. Streaming	เทียบเวลาเผยแพร่ของข่าวกับเวลาที่แสดงบนเว็บ และหยุดระบบกลางคืนแล้วเปิดใหม่	end-to-end latency, ข่าวสูญหาย	$\leq$ 15 นาที, ไม่สูญหาย 7 วัน
3. FinBERT	ทีมติดป้าย 300 ข่าวแยกกัน แล้วเทียบกับผลโมเดล	Macro-F1, Cohen's kappa ระหว่างผู้ติดป้าย	F1 $\geq$ 0.70

วัตถุประสงค์	วิธีวัด	ตัวชี้วัด	เป้าหมาย
4. เว็บแอป	ผู้ใช้ 10 คนทำงานที่กำหนด แล้วตอบแบบสอบถาม	SUS	≥ 68
5. LLM สรุปรข่าว	ตรวจ 50 สรุปรเทียบข่าวต้นทาง	สัดส่วนที่ไม่แต่งข้อมูล, สอดคล้องกับ FinBERT	≥ 90%

8. ประโยชน์ที่คาดว่าจะได้รับ

ต่อผู้ใช้

- ดูทิศทางข่าวของหุ้นที่สนใจได้ในหน้าเดียว ไม่ต้องเปิดหลายแหล่ง
- อ่านสรุปล้นแทนข่าวทั้งหมด และถามต่อได้พร้อมแหล่งอ้างอิง
- เห็นว่า sentiment ของข่าวสอดคล้องหรือสวนทางกับราคาปิด

ด้านวิชาการ

- ได้สถาปัตยกรรม Data Lakehouse ที่รวม batch และ streaming พร้อมผลทดสอบประสิทธิภาพที่วัดได้จริง
- ได้ผลประเมิน FinBERT และ LLM บนข่าวหุ้นจริง ซึ่งใช้อ้างอิงต่อได้
- ผู้จัดทำได้ประสบการณ์ Data Engineering และ AI Engineering บน AWS ตั้งแต่ต้นจนจบ

9. ข้อจำกัดและความเสี่ยง

ความเสี่ยง	ผลกระทบ	แนวทางรับมือ
ข่าวมีปริมาณไม่มาก (ประมาณวันละ 500 ข่าว)	อาจถูกถามว่าทำไมต้องใช้ Data Lakehouse	พิสูจน์ด้วยความสามารถ (time travel, reprocess จาก Raw, batch + streaming ในตารางเดียว) แทนปริมาณ และระบุเป็นข้อจำกัด
API ฟรีจำกัดจำนวนครั้ง	ข่าวสดช้ากว่าจริง 5-15 นาที	ใช้คำว่า near real-time และรวมหลายแหล่ง
เริ่มระบบใหม่ยังไม่มีข่าวสะสม	หน้าเว็บและ RAG มีข้อมูลน้อยช่วงแรก	เปิด pipeline เก็บข่าวให้เร็วที่สุด
yahoofinance ไม่ใช่ API ทางการ	อาจโดนบล็อกชั่วคราว	ดึงวันละครั้งและเว้นจังหวะ
ค่าใช้จ่าย AWS และ LLM	เกินงบประมาณ	ตั้ง budget alert และวัดค่าใช้จ่ายต่อคำถาม