

ชีพजरหุ้น (Stock Sentiment Pipeline)

Phase 1 (Data Engineering) | Project Overview

1. Mission Overview

โปรเจกต์นี้มุ่งพัฒนาระบบ Data Pipeline ที่รวบรวมข้อมูลราคาหุ้นและข่าว/โซเชียลมีเดีย มาวิเคราะห์ sentiment แล้วแสดงความสัมพันธ์ระหว่างอารมณ์ข่าวกับความเคลื่อนไหวของราคาหุ้นผ่าน dashboard ที่เข้าใจง่าย

โปรเจกต์แบ่งเป็น 2 เฟส: เฟส 1 เน้นด้าน Data Engineering สร้าง pipeline ให้รันได้ครบวงจรตั้งแต่ ingest จนถึง dashboard เฟส 2 (เริ่มต้นปีหน้า) จะต่อยอดด้าน AI Engineer เช่น model serving, RAG chatbot และ monitoring ซึ่งไม่อยู่ในขอบเขตของเอกสารนี้

2. Problem Statement

นักลงทุนและนักวิเคราะห์ที่ต้องการติดตามความเคลื่อนไหวของหุ้น มักต้องเปิดหลายแหล่งข้อมูลพร้อมกัน (แอปราคาหุ้น, เว็บไซต์, โซเชียลมีเดีย) แล้วประเมินเองว่าข่าวที่ออกมาส่งผลกระทบต่อราคาอย่างไร ซึ่งใช้เวลาและอาศัยประสบการณ์ส่วนตัว ในการตีความ

ปัญหาคือข้อมูลราคาหุ้นและข้อมูลข่าว/sentiment กระจัดกระจายอยู่คนละแหล่ง ไม่มีระบบที่รวบรวมและแสดงความสัมพันธ์ของทั้งสองอย่างแบบ real-time ในทีเดียว ทำให้ยากต่อการตัดสินใจอย่างทันท่วงที

โปรเจกต์นี้จึงต้องการสร้างระบบที่รวบรวม ประมวลผล และแสดงผลข้อมูลทั้งสองประเภท โดยอัตโนมัติ พร้อมระบุแหล่งที่มาของข้อมูลอย่างชัดเจน โดยไม่สับสนเกินกว่าข้อมูลที่มี (เช่น ไม่ฟันธงว่าข่าวเป็น "สาเหตุ" ของการเปลี่ยนแปลงราคา เป็นเพียงข้อมูลประกอบการตัดสินใจ)

3. Target Users

3.1 นักลงทุนรายย่อย (Retail Investor)

ใช้ dashboard เพื่อติดตามราคาหุ้นที่สนใจ พร้อมดูภาพรวม sentiment ข่าวล่าสุดประกอบการตัดสินใจซื้อ/ขาย

3.2 นักวิเคราะห์ข้อมูล/นักศึกษาที่สนใจสาย Data

ใช้ระบบเป็นตัวอย่างในการศึกษาสถาปัตยกรรม Data Lakehouse และ pipeline แบบ real-time

3.3 อาจารย์ที่ปรึกษา/กรรมการสอบ

ใช้มุมมอง System Health เพื่อประเมินความสมบูรณ์ของระบบ data engineering เบื้องหลัง

4. เป้าหมายโปรเจก (Goals)

ระบบควรช่วยตอบคำถามเหล่านี้ได้:

- ราคาหุ้น X ตอนนี้เป็นอย่างไร เทียบกับช่วงเวลาก่อนหน้า
- Sentiment ของข่าว/โซเชียลเกี่ยวกับหุ้น X ในช่วงเวลาล่าสุดเป็นบวกหรือลบ
- มีข่าวใดล่าสุดที่อาจเกี่ยวข้องกับการเปลี่ยนแปลงราคา
- แนวโน้มราคาและ sentiment สอดคล้องกันหรือไม่ในแต่ละช่วงเวลา
- ระบบ pipeline เบื้องหลังทำงานปกติหรือไม่ (สำหรับมุมมองผู้ดูแลระบบ/อาจารย์)

5. Scope for Phase 1 (11 สัปดาห์: 15 ก.ย. – 30 พ.ย.)

In Scope

- ดึงข้อมูลราคาหุ้นแบบ real-time จาก pool หุ้นประมาณ 50 ตัว (คัดจากหลาย sector) ผ่าน public API
- ดึงข้อมูลข่าว/โซเชียลที่เกี่ยวข้องจาก RSS feed และ/หรือ Twitter API
- ประมวลผล sentiment เบื้องต้นด้วยโมเดลที่มีอยู่แล้ว (LSTM/FinBERT แบบ pretrained, รันแบบ inline)
- จัดเก็บข้อมูลบน Data Lakehouse (MinIO + Apache Iceberg + Nessie catalog)
- สร้าง dashboard แสดงราคา, สัดส่วน sentiment, กราฟความสัมพันธ์ และ live news feed
- แสดงมุมมอง System Health พื้นฐาน (Kafka delay, Spark status, Nessie branch) สำหรับตรวจสอบระบบ
- ผู้ใช้เลือกหุ้นจาก pool ที่มี เพื่อเพิ่มเข้า watchlist ส่วนตัวก่อนเข้าดู dashboard

Future Scale-up (หลังเฟส 1 สำเร็จ)

- ขยาย 50 ตัว เป็นทั้ง S&P 500 (~500 ตัว) โดยใช้ schema เดิมที่ออกแบบไว้รองรับอยู่แล้ว

Out of Scope

- การแยกโมเดล sentiment เป็น API service ต่างหาก (เฟส 2)
- RAG/chatbot ถามตอบเกี่ยวกับข่าว (เฟส 2)
- Model monitoring/drift detection แบบเต็มรูปแบบ (เฟส 2)

- การรองรับหลายหุ้นพร้อมกันจำนวนมาก หรือ production-grade authentication
- การยืนยันความแม่นยำของ sentiment model ในเชิงวิชาการ (ใช้โมเดลที่มีอยู่แล้วเป็นหลัก)

6. Required Input

6.1 Stock Price Data

ราคาหุ้นแบบ real-time หรือใกล้เคียง real-time จาก API เช่น Yahoo Finance, Alpha Vantage สำหรับหุ้นใน 50 ตัวที่คัดไว้

6.2 News & Social Data

ข่าวการเงินจาก RSS feed ของสำนักข่าว และ/หรือ โพสต์จาก Twitter/X ที่เกี่ยวข้องกับหุ้น

6.3 Historical Data (สำหรับเปรียบเทียบ)


ข้อมูลราคาหุ้นย้อนหลังในช่วงสั้นๆ เพื่อใช้เปรียบเทียบแนวโน้มในกราฟ

7. Required Features

Feature	รายละเอียด
1. Stock Selection	เลือกหุ้นจาก 50 ตัว (filter ตาม sector, ค้นหาได้) เพื่อเพิ่มเข้า watchlist ส่วนตัว
2. Watchlist Overview	แสดงเฉพาะหุ้นที่เลือกไว้เป็นการ์ด: ราคา, % เปลี่ยนแปลง, sentiment badge, กราฟย่อ
3. Price Dashboard	แสดงราคาปัจจุบัน, % เปลี่ยนแปลง, กราฟราคาตามเวลา (หน้ารายละเอียดของหุ้นที่เลือก)
4. Sentiment Overview	แสดงสัดส่วนข่าว positive/neutral/negative ในช่วงเวลาล่าสุด
5. Price vs Sentiment Chart	กราฟรวมแสดงราคาหุ้นและ sentiment score บนแกนเวลาเดียวกัน เพื่อดูรูปแบบความสอดคล้อง
6. Live News Feed	ตารางข่าวล่าสุดพร้อมแหล่งที่มาและ sentiment score รายข่าว
7. System Health View	แสดงสถานะ pipeline เบื้องหลัง (Kafka, Spark, Iceberg/Nessie) สำหรับตรวจสอบระบบ

8. ภาพตัวอย่างการแสดงผล (UI Flow)

ผู้ใช้เลือกหุ้นเข้า watchlist ก่อน จากนั้นดูภาพรวม watchlist แล้วคลิกเข้าไปดู dashboard รายละเอียดของหุ้นที่สนใจ:



9. ผลลัพธ์ที่คาดว่าจะได้รับ (Expected Deliverables)

- Data pipeline ที่ทำงานจริง (Kafka → Spark → Iceberg) รับข้อมูล real-time ได้ต่อเนื่อง
- Data Lakehouse บน MinIO + Iceberg + Nessie ที่มี layer raw/cleaned/aggregated
- Web dashboard ที่แสดงราคาหุ้น, sentiment, และความสัมพันธ์ของทั้งสอง
- เอกสาร system design และรายงานสรุปผลการทำงานของ pipeline
- ข้อกำหนดของระบบและแผนต่อขยายสำหรับเฟส 2

10. Non-functional Requirements

- Idempotency: ป้องกันข้อมูลซ้ำด้วย Iceberg merge/upsert

- Fault tolerance: Kafka consumer group และ Spark checkpointing กรณีระบบล่ม
- Data quality: ตรวจ schema, ค่า null, ราคาผิดปกติก่อนเข้า cleaned layer
- Scalability: ออกแบบให้เพิ่มจำนวนหุ้นหรือแหล่งข่าวในอนาคตได้โดยไม่ต้องปรับสถาปัตยกรรมใหม่

11. ข้อจำกัดของเฟส 1

ระบบในเฟส 1 ใช้ sentiment model ที่มีอยู่แล้วแบบ pretrained รันภายใน pipeline โดยตรง ยังไม่มีการแยกเป็น service, ยังไม่มีระบบ monitoring ความแม่นยำของ โมเดล ในระยะยาว และยังไม่มีการตอบเชิงลึก (RAG) ส่วนเหล่านี้จะดำเนินการต่อในเฟส 2 (1 ม.ค. – เม.ย.) ซึ่งเน้นด้าน AI Engineer โดยเฉพาะ

12. Key Message

โปรเจกต์นี้ไม่ใช่การสร้างแอปราคาหุ้นทั่วไปที่มีแค่กราฟราคา และไม่ใช้ระบบที่ฟันธงว่าข่าวคือสาเหตุของการเปลี่ยนแปลงราคา ความท้าทายคือการสร้าง pipeline ที่รวบรวมข้อมูลสองประเภทที่ต่างกันมาก (ตัวเลขราคาและข้อความข่าวแบบไม่มีโครงสร้าง) ให้ไหลเข้าสู่ระบบเดียวกันได้อย่างน่าเชื่อถือ ตรวจสอบย้อนกลับได้ และแสดงผล ในรูปแบบที่ช่วยให้ผู้ใช้เห็นสัญญาณที่น่าสนใจ โดยไม่สรุปเกินกว่าข้อมูลที่มี